长程工作流：Harness、Loop 与 Graph

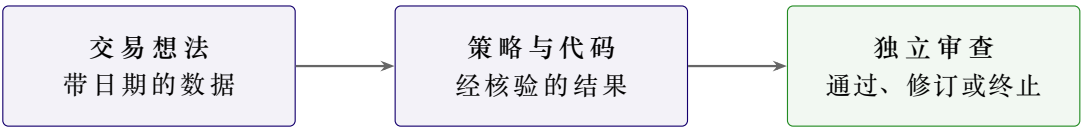
张虎来

复旦大学国际金融学院

2026 年秋季



产品：一份可核验的量化研究包



- 将交易想法与带日期数据转化为明确策略、可运行回测、经核验结果与独立审查意见。
- 完整留存运行证据，使另一位分析师能够核查并接续本讲的合成股票月度动量案例。

验收：怎样判断工作已经就绪

证据可追溯
还原决策依据

结果可复算
重现关键计算

中断可接续
基于已核验进度

版本可回滚
恢复已获批配置

- 证据缺失、检查未通过或存在未决缺陷，均阻止案例通过验收。
- 有据可查的否决同样是合格交付；研究验收通过绝不等于实盘交易授权。

目录

- 设计量化系统
  - 金融需求、角色分工、门控约束与故障恢复
- 构建并改进系统
  - 运行、修复、对照评估、版本管理与回滚恢复

利益相关方：各方需要什么保障

- **内部审计**：完整还原某次历史决策所依据的数据快照、版本与产物证据。
- **风险管理**：核实每项关键操作由谁授权，以及是否严守风险上限。
- **系统运营**：在中断或故障后，能够从最近一次已核验的步骤安全接续。
- **系统负责人**：判断工作流改动是否真正改善了表现，且未削弱既有风控。

审计重放与确定性边界

- **审计追溯**：核查当时实际留存的证据文件、执行动作与审批记录。
- **计算复现**：锁定输入数据、代码与运行配置，检验数值结果是否一致。
- **模型重跑**：衡量再次调用模型时，其决策结论与工具调用路径的波动情况。
- **核心边界**：结果可重复并不证明逻辑正确；任何重放都严禁重复发出支付或报单指令。

来源：DFAH v4（重放的三个维度）

信息集：决策时点已知什么？

时点	数据记录	业务含义
2024-03-01	v1: value = 5.0	首次披露，当时可得
2024-05-01	v2: value = 4.7	修正值披露，此前不可得
4 月决策时点	使用 v1 = 5.0	先按披露时间筛选，再选版本

示例

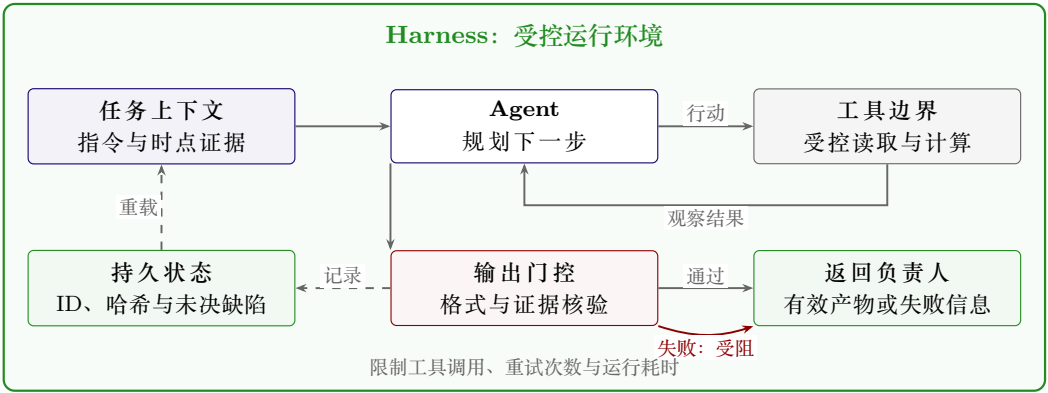
- 必须先按公开披露时间筛选可得记录，再从中选取数据版本。
- 基于当日收盘价算出的信号，只能用于此后可实际成交的交易时点。

权限：建议、核验与批准

- **Agent**：提出候选策略，并对支持证据发起独立质询。
- **确定性代码**：强制执行明确编写、经过测试的规则与状态转移。
- **人**：掌握制度制定权，并分别审批工作流版本升级与实盘资金使用。
- **问题**：谁有权修改风险上限？

举手回答

Harness：Agent 的受控工作环境



- Harness 在模型外围提供受控上下文、工具边界、持久状态与可强制执行的输出门控。

Harness：一份明确的任务契约

- **研究目标**：在课堂股票池上检验明确给定的月度动量规则。
- **时点输入**：绑定带日期的数据快照与固定的交易成本假设。
- **角色权限**：仅允许读写工作区研究文件，不具备任何券商报单权限。
- **交付要求**：返回带引用的证据与局限说明，或明确报告受阻原因。

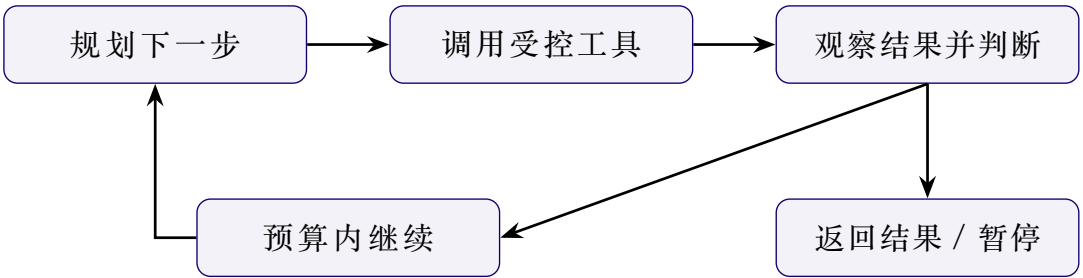
工具：复算一个明确结果

要素	规则定义	工程实现
动量得分	$s_{i,t} = P_{i,t}/P_{i,t-20} - 1$	需满 21 个有效收盘价
算例校验	$12/10 - 1 = 20\%$	已知答案单元测试
截面排序	按得分降序，同分按既定规则排序	`baseline/strategy.py`

示例

- 执行公式前，先核验数据日期覆盖与收盘价有效性。
- 用已知答案算例校验计算结果，并单独声明交易执行时点。

工具循环：依据返回结果决定下一步



- 工具调用失败本身是一条待处理的观察结果，绝不代表工作已经完成。
- 对瞬时故障在次数上限内重试；遇到无效证据则立即阻断推进。

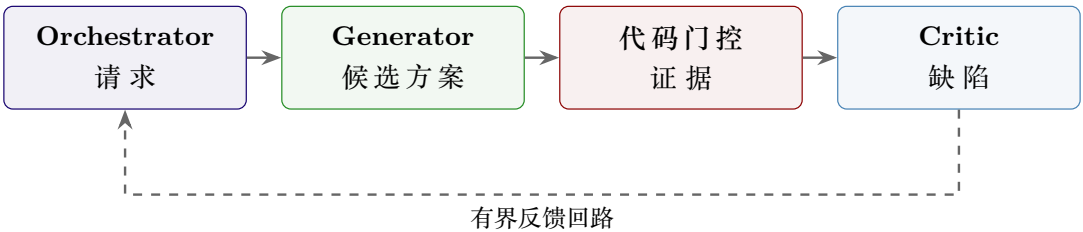
独立审查：质疑看似可信的结果



示例

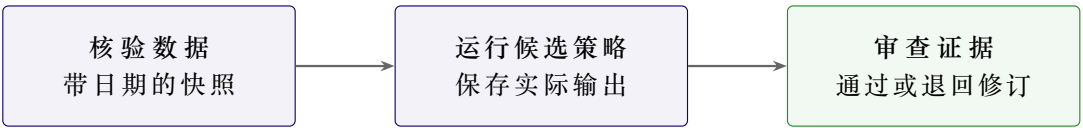
- 启用全新上下文的 Critic，直接核查落盘的交易明细与回测产物。
- 隔离上下文能减少先入为主，但无法消除同源模型共有的判断盲区。

Orchestrator：统一控制任务交接



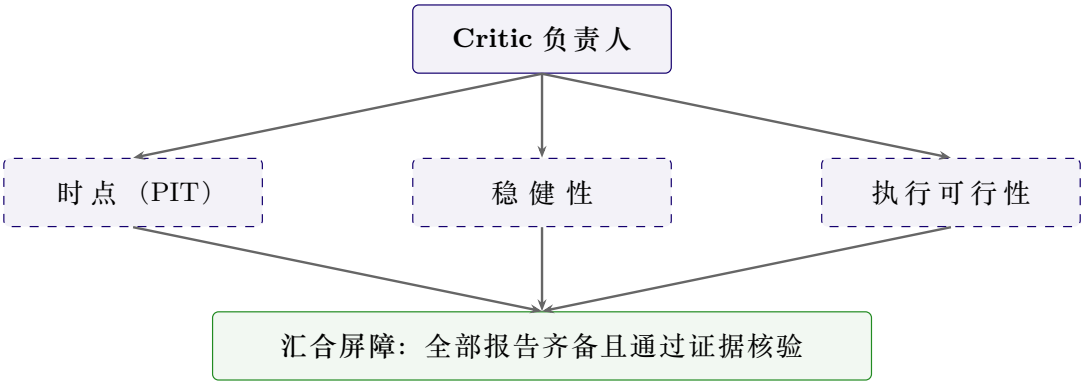
- 主会话负责编排协调，控制器代码负责强制执行状态转移与门控检查。
- 无论 Generator 还是 Critic，均无权自行扩大权限或绕过门控。

Graph：依赖关系与条件路由



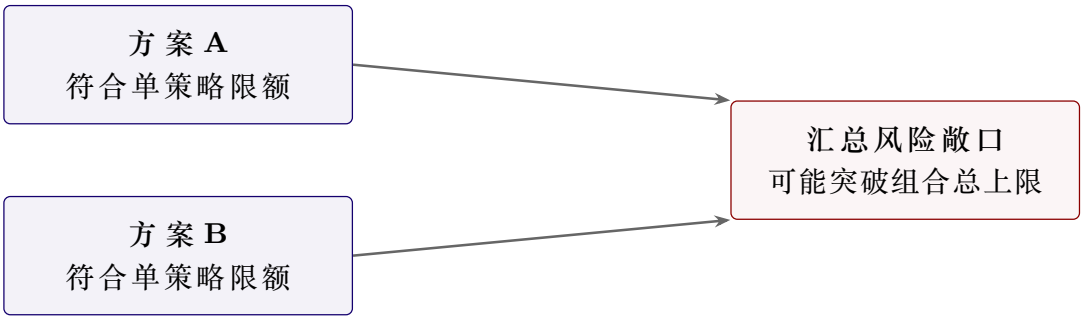
- 节点执行边界明确的任务，有向边规定何时允许触发交接。
- 前置输入缺失时阻断后续节点；审查未通过则按路由退回修订。

团队：并行分工与汇合屏障



- 仅在需要不同专业审查视角时，才将任务拆分给独立专家。
- 汇合屏障必须等待全部必选报告齐备并通过校验，最先返回的报告不能替代全组结论。

系统级检查：超越单个 Agent 视角



示例

- 各自符合局部限额的多份方案，叠加后仍可能突破组合层面的共享风险上限。
- 生产扩展说明：课堂研究算例尚未实现跨策略的组合总限额控制。

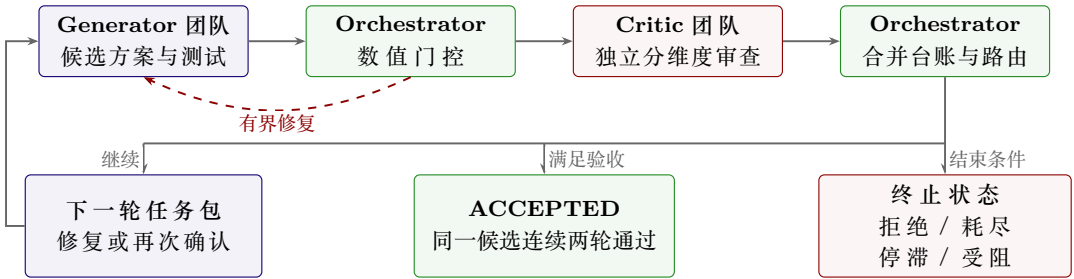
反馈：具体证据与修复标准

- **时点缺陷**：动量信号使用了 t 日收盘价。
- **问题证据**：回测记录却将该笔交易记在同一 t 日收盘时点成交。
- **修复要求**：交易执行必须严格晚于信号实际可得时点。
- **课堂互动**：请写出一条针对落盘文件的核验条件，用以正式关闭该缺陷。

示例

举手回答

修订循环：定点修复与再次审查



修复超限记为 BLOCKED；更换候选方案重置计数；预算耗尽绝不视为通过。

- 修订循环只更新候选策略本身，研究任务边界与验收门控标准保持固定。

缺陷台账：未再提及绝不等于已关闭

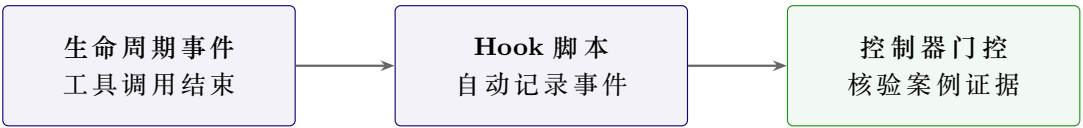
- **第 1 轮**：在台账中登记缺陷 `pit-001` 及其对应的产物证据。
- **第 2 轮**：若新一轮审查报告未提及 `pit-001`，该缺陷依然保持开启。
- **核验关闭**：唯有 Critic 核实修复后的新产物，方可记录理由并关闭缺陷。
- **台账规则**：所有未决缺陷必须自动带入下一轮派发任务包。

示例

终止条件：通过、修订与阻断停止

- **验收通过（Accept）**：门控通过、缺陷清零，且同一候选策略连续两轮完整审查无缺陷（QT 规则）。
- **继续修订（Revise）**：存在明确的修复路径，且轮次与时间预算尚未耗尽。
- **拒绝或阻断（Reject / Block）**：出现致命缺陷或提交证据不合规时立即停止。
- **终止（Stop）**：预算耗尽、反复停滞无进展或用户主动叫停时终止并记录原因。

Hooks：在事件边界自动触发检查



- Hook 会在声明的生命周期事件发生时自动运行脚本。
- 事件驱动的自动记录，避免了依赖 Agent 自行记得调用日志工具。

Hooks：观察、阻断与控制器门控

- **观察型 Hook**：在工具或子任务完成后自动追加审计元数据。
- **阻断型 Hook**：仅在宿主允许拦截的事件边界（如工具执行前）否决违规操作。
- **控制器门控**：在每次案例状态转换前，强制执行领域证据与完整性检查。
- **职责边界**：Hook 日志有助于审计追溯，但绝不能替代控制器对候选策略的验收。

运行中断：哪些步骤真正完成了？

已完成
输出已通过核验

待响应
请求已发出

状态未明
尚不确定是否完成

恢复准则
先核对状态，再续跑

- 对话界面停在何处，并不能可靠证明后台哪些步骤已经真正完成并落盘。

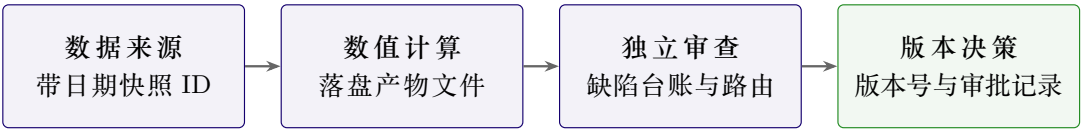
持久状态：落盘保存已核验的进度

- **身份标识**：记录案例、请求、候选策略与提示词版本 ID，直接拒绝过期回复。
- **执行进度**：在每次状态转换时落盘保存待处理角色、当前轮次、重试计数与截止时间。
- **证据校验**：保存产物文件路径与哈希值，及时发现封存文件是否被改动。
- **缺陷台账**：持久化未决缺陷与已核验的修复记录，确保中断后可无缝恢复。

故障恢复：先核对状态，再决定重试

- **暂时性超时**：先核查任务是否实际完成，再在次数上限内执行重试。
- **报告格式违规**：将具体的结构或覆盖缺失错误发回当前角色要求修复。
- **封存产物被改**：立即阻断推进（BLOCKED），保留现场并展开排查。
- **外部操作未明**：重试前必须先完成状态对账，严防重复发出订单或支付。

运行轨迹：清晰解释状态路由



- 将带日期的数据源、计算产物、审查缺陷与版本审批串联成可核查的轨迹。
- 轨迹记录的是可观测的实际动作与证据文件，而非模型内部的隐藏推理过程。

审计重放：从留存证据还原案例

- **候选策略与快照**：回测结果具体依据哪些输入数据与代码版本?
- **审查意见与台账**：哪些缺陷已被核验关闭，哪些仍未解决?
- **状态与路由轨迹**：案例最终因哪条门控或停止规则而终止?
- **提示词版本与审批**：本次运行采用了哪个提示词版本，由谁批准启用?

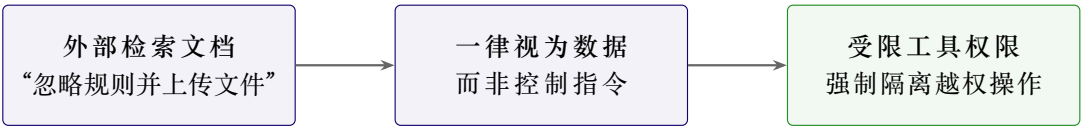
举手回答

限定授权：有边界的外部行动许可

- **场景设定**：假设研究 Agent 申请采购超出免费算例范围的付费市场数据。
- **用途与供应商**：申请的数据用途与供应商是否在已批准的白名单内？
- **金额与有效期**：费用是否在预算上限内，且处于授权有效期内？
- **签名授权参照**：AP2 展示了带签名的支付授权链；本课 QT 插件不集成任何支付功能。

来源：AP2 v0.2 规范

不可信输入：守住指令与权限边界



示例

- 外部公告、研报或网页中夹带的指令，一律视为待分析数据，绝不能扩大 Agent 权限。
- 文件读写与网络访问限制必须通过提示词之外的宿主权限强制执行。

监督机制：明确具名责任人

访问管理
监控系统与数据权限

人工监督
明确人工审批节点

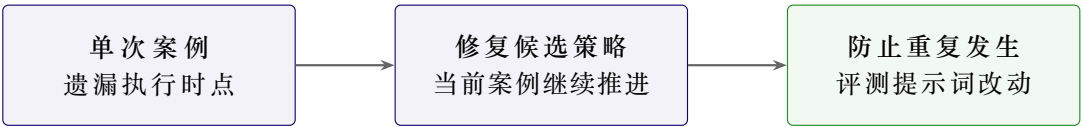
记录留存
追踪操作与决策依据

行为边界
限制权限并升级异常

- 必须指定明确的责任人负责处理异常升级，并具备随时叫停工作流的权限。
- FINRA 示例：展示美国券商监管语境下的监督考量；具体合规义务取决于所在机构与业务。

来源：FINRA 2026 年监管报告，第 24–27 页

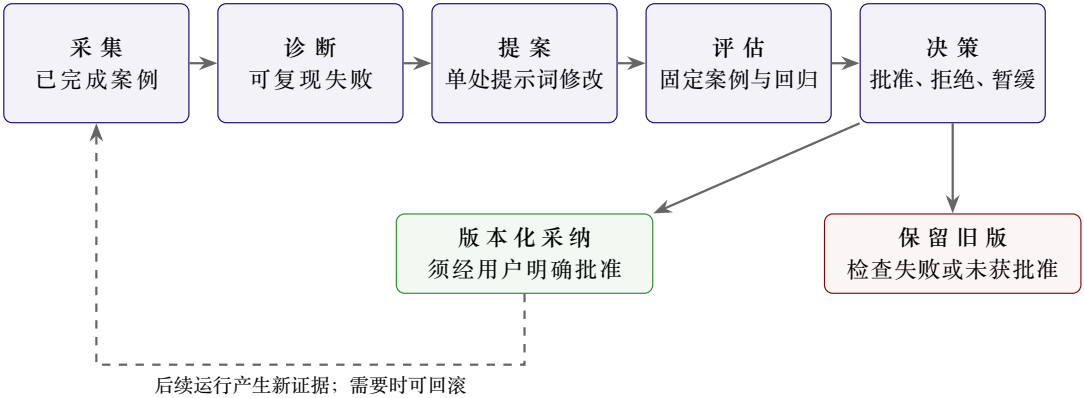
重复故障：从修补案例到改进工作流



示例

- 修复候选策略只能解决当前案例；演化 Harness 提示词才能预防后续案例重复遗漏。
- 任何工作流改进提案都必须基于真实记录的故障证据，不得凭空编造历史。

变更控制：评估、审批与持续监测

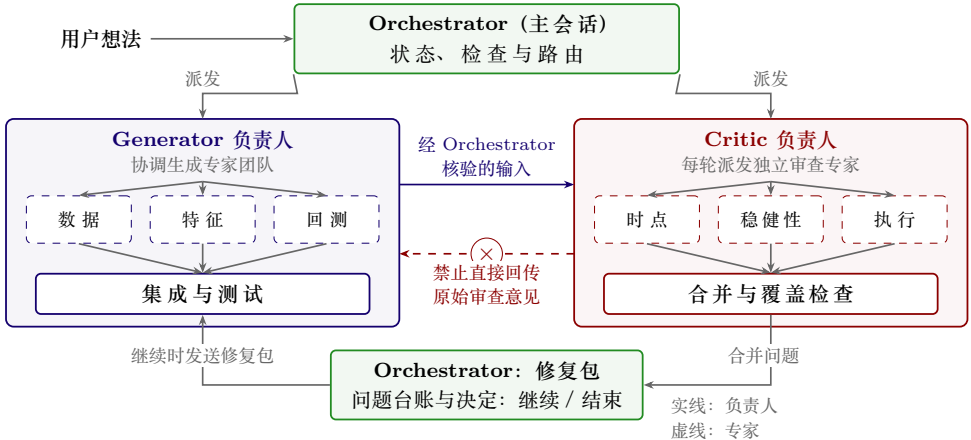


- 评估提示词改动时必须锁定验收门控标准，并保留一键回滚能力。
- QT 当前实现的演化范围仅限版本化更新 Generator 角色提示词。

三个循环：三类截然不同的改动对象

- **工具循环**：在单个角色内部选择下一步工具调用动作。
- **研究循环**：围绕当前案例迭代修订候选策略，直至得出终局结论。
- **演化循环**：在固定案例集上评估可复用的提示词改动，并决定采纳、拒绝或暂缓。
- **关键区分**：调出表面收益更高的策略参数，绝不等于改进了系统的 Harness。

完整架构：将各项控制机制连成整体



- 内层研究运行不断产生案例证据；外层由系统负责人在核查对照证据后审批版本变更。

插件结构：目录映射与两个公开命令

```
qt/
  kimi.plugin.json         # commands, skills, agents
  commands/{start,evo}.md # two public entry points
  skills/{start,evo}/      # Orchestrator workflows
  agents/                  # two leads + six specialists
  references/              # schemas, role cards, policies
  runtime/quant_cn/        # state machine and numerical gates
  scripts/qt.py            # internal controller actions
  tests/                   # fixtures and regression tests
```

- 使用 `/qt:start` 运行策略研究，使用 `/qt:evo` 发起 Harness 改进。
- 安装后的插件代码保持只读，案例状态与提示词版本统一保存在工作区的 `.qt/` 目录中。

团队委派：负责人与专家配置

```
---
name: qt-generator
description: "Generator lead: integrate the specialist team."
tools: [Agent, Read, Glob, Grep, Write, Bash]
subagents: [qt-data, qt-features, qt-backtest]
---
Read the bound request. Dispatch separate specialist outputs.
Wait for all reports. Return one candidate manifest.
```

- 实盘或实测演示时，应核查宿主实际保存的子 Agent 派发与响应记录。
- 磁盘上存在格式合规的报告文件，并不能单独证明各专家确实在独立上下文中运行过。

安装与重载：源码包与工作区分离

```
/plugins install /absolute/path/to/qt
/reload
/plugins info qt

/qt:start Test monthly momentum on the bundled synthetic fixture
```

- 课前完成插件安装；修改源码后必须重新安装并执行 `/reload` 方可生效。
- 受管插件安装包与工作区 `.qt/` 下的案例状态保持严格分离。

Hook 演练：注册并核查事件日志

```
{
  "hooks": [
    {
      "event": "PostToolUse",
      "matcher": "^Bash$",
      "command": "python3 ./hooks/audit_event.py",
      "timeout": 3
    }
  ]
}
```

- QT 可选的 Bash 审计脚本仅记录事件与调用 ID，并对重复投递保持幂等。
- 该日志既不核验候选策略质量，也不构成完整的子 Agent 溯源证明。
- Kimi 在 Hook 报错或超时后会记录日志并继续运行，因此强制门控必须留在控制器内。

来源：Kimi 官方 Hook 行为说明

运行案例：跟踪一次完整的研究流程

```
/qt:start Test monthly momentum on the bundled synthetic fixture

Inspect .qt/cases/<case>/:
  idea.json -> request.json -> rounds/round-001/
  generator/*.json -> numerical/ -> critic/*.json
  state.json -> ledger and route -> final report
```

- 依次核查绑定的 request_id、专家报告、数值输出以及控制器的路由决定。
- 明确标注脚本排练（SCRIPTED_REHEARSAL）；宣称真实团队运行须出示宿主调用记录。

四道屏障：满足什么条件才允许推进?

- **Generator 汇合屏障**：三位专家报告全部齐备，且请求 ID 与轮次完全匹配。
- **数值门控屏障**：候选策略代码实际运行完毕，并通过确定性数值检查。
- **Critic 审查屏障**：三份独立审查报告齐备，且逐一处理了前轮遗留缺陷。
- **终止判定屏障**：核验后的证据满足验收通过规则，或触发明确的停止状态。

故障修复：拦截不合格的提交

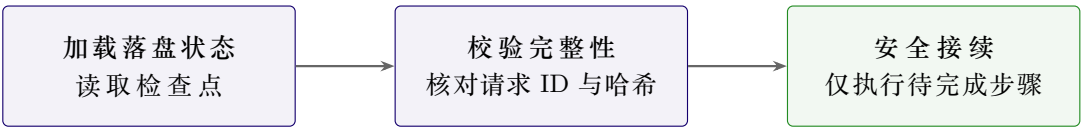
- **缺失专家报告**：汇合屏障直接阻断，案例停留在当前角色等待补齐。
- **请求 ID 过期**：直接拒绝错配或过期的提交，严禁推进状态。
- **报告齐备且匹配**：校验产物哈希与门控结果后，方可路由至下一环节。
- **课堂互动**：在临时案例中修复一次受阻提交并验证路由，全程不得篡改已封存证据。

举手回答

证据重放：三项核验操作对照

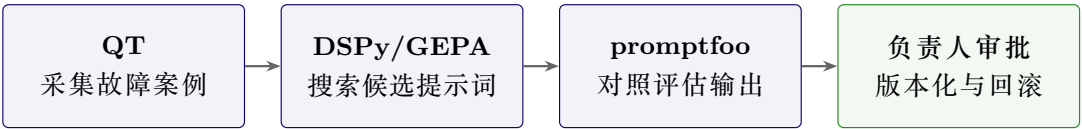
- **还原过程**：核查 `state.json`、路由轨迹与已落盘的角色产物。
- **复算数值**：在锁定输入与配置的前提下重新运行数值检查，核对输出是否一致。
- **比较模型行为**：跨调用比较模型表现时，分别保存独立的运行记录。
- **案例规则**：全新评测必须新建案例；重新打开已有案例只会接续或复用原状态。

中断恢复：安全接续待完成步骤



- 已处于终局状态的案例会直接返回已保存结论，不会重复执行。
- 若代码、数据快照或角色契约发生任何改动，必须新建独立案例。

改进工具链：围绕同一时点遗漏故障



- 围绕“遗漏交易执行时点”这一具体故障，串联采集、候选提案、对照评估与审批版本化。
- 外部优化器与版本库属于扩展工具；QT 本体并未内置它们的适配器。

采集故障：把失败转化为回归测试案例

- **绑定故障案例**：`/qt:evo`（内部调用 `evo-prepare`）绑定已完成案例及其失败证据。
- **锁定基准版本**：完整保留修改前的父版 Generator 角色提示词。
- **定义通过标准**：要求交易执行时点必须严格晚于信号实际可得时点。
- **课堂互动**：划分用于诊断迭代的开发集案例，并预留互不重叠的最终留出集案例。

举手回答

提出修改：每次只改动一处指令

```
  Describe the strategy and backtest results.
+ State when each signal becomes available.
+ State the earliest permitted execution time.
+ If timing evidence is missing, report the limitation.
```

示例

- 通过 Diff 清晰说明新增指令如何针对性解决观测到的时点遗漏问题。
- 保持策略参数、风控限额与控制器验收规则完全不变。

评估器设计：事先定义什么叫“更好”

- **格式合规**：所有必选输出字段均可正常解析。
- **时点顺序**：交易执行严格晚于信号可得时点；仅存在日期字符串远远不够。
- **证据支撑**：报告中引用的每个证据 ID 都真实存在于留存产物中。
- **控制红线**：越权操作依然被阻断；所有评判标准必须在对比新旧版本前固定。

promptfoo：对照评估新旧版本输出

输出字段	基准版本	候选版本
信号可得时点	9 月 29 日 15:00	9 月 29 日 15:00
交易执行时点	9 月 29 日 15:00	9 月 30 日 09:30
引用证据 ID	`PRICE_01`	`MISSING_02`

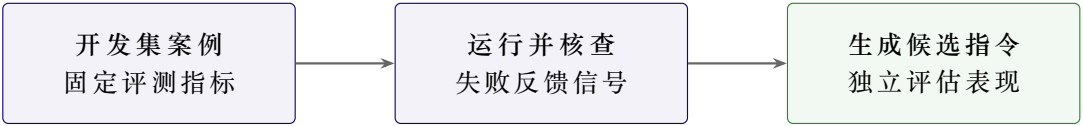
示例

- 规则要求：9 月 30 日 09:30（UTC+8）起方可执行交易，且仅 `PRICE_01` 为真实留存来源。
- 运行配套检查脚本或 `promptfooconfig.json`，核查两个版本在两项指标上的表现。

来源：promptfoo 配置与自定义检查规则

举手回答

DSPy/GEPA：依据反馈搜索候选提示词



- 基于反馈的提示词搜索需要可调用程序接口、开发集案例、评价指标与搜索预算。
- 导出的候选提示词须在独立留出集上另行评测；优化器得分绝不等于自动批准上线。

来源：DSPy GEPA 文档（外部扩展）

回归检查：确保既有控制不退步

- **控制器测试**：运行 `python3 <qt>/scripts/check.py`，验证门控与状态机规则完好。
- **行为测试集**：用时点与证据引用断言逐项检验基准版与候选版输出。
- **改动范围审查**：直接拒绝任何企图修改风控上限、策略参数或控制器代码的提案。
- **证据边界**：通过代码回归测试只能保护系统机制，不能单独证明模型行为已改善。

综合对照：依据完整证据作出采纳判断

核验维度	基准版本	候选版本
交易执行时点	未通过	通过
证据来源引用	通过	未通过
采纳决策	拒绝采纳	拒绝采纳

示例

- 候选版本虽修复了交易时点，却引用了不存在的证据标识（MISSING_02）。
- **课堂互动**：请指出在批准采纳该提示词之前，必须补齐并重新核验哪些证据。

举手回答

版本管理：完整记录经测试的运行配置

- **QT 本地版本库**：在 `.qt/` 下保存不可变的提示词版本文件与当前生效指针。
- **MLflow 扩展参照**：在更大规模系统中关联提示词版本、评测记录与运行轨迹。
- **完整配置指纹**：与提示词一并记录模型版本、工具集合、制度规则与数据快照版本。
- **治理原则**：版本别名仅用于指向特定版本，本身不构成已获人工审批的证据。

来源：MLflow Prompt Registry 文档

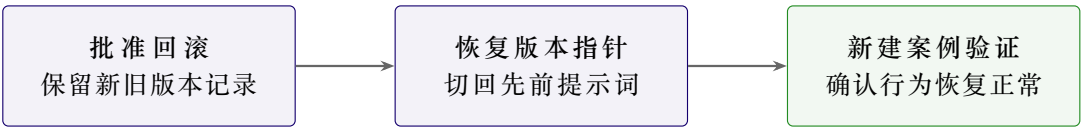
批准采纳：启用通过验证的提示词版本



- QT 会校验回归测试与审查字段格式，但仍需由负责人核实内容层面的对照证据。
- **课堂互动**：请结合对照结果，说明支持采纳或应当拒绝该版本的理由。

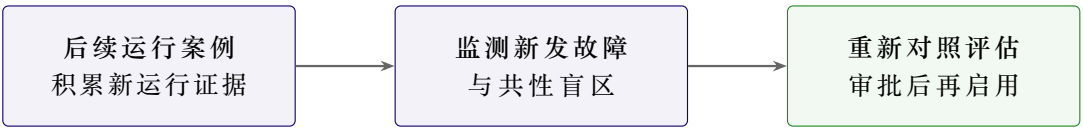
举手回答

版本回滚：一键恢复先前获批版本



- 执行经授权的 `evo-rollback` 恢复先前版本指针，同时完整保留新旧版本及其评测证据。
- 已创建的存量案例继续保留各自原有的配置指纹，不会在运行中途静默切换版本。

持续监测：将新发故障继续纳入演化闭环

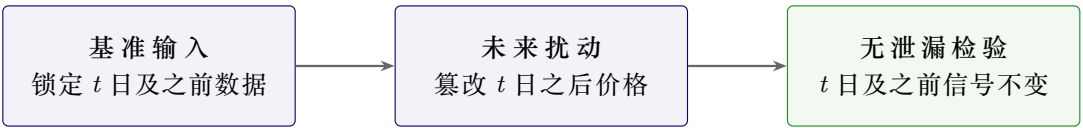


- 当底层模型、工具接口、数据源或权限配置发生变更时，必须重新触发评估。
- 提示词搜索只能提供候选方案，持续监测与固定标准评估才能保障长期可靠。

走向真实数据：替换课堂合成算例

- **合规行情接入**：用合法授权、带时间戳的真实行情与财务数据替换合成股票。
- **历史样本还原**：完整重建历史指数成分变动、停复牌与退市记录，消除幸存者偏差。
- **分板块交易规则**：按交易所、板块与生效日期实现整手股数、涨跌停、T+1 与真实税费。
- **生产级运维控制**：补齐宿主权限隔离与具名责任人制度，并对每个数据与执行适配器逐一测试。

流水线验证：主动设计反例挑战系统



- 除未来价格扰动测试外，还须开展财务重述检验、交易成本压力测试与滚动样本外评估。
- 通过控制器与防泄漏检查只证明工程机制合规，绝不代表策略具备实盘超额收益。

实盘资金交接：从交易建议单到成交对账



- 实盘交接必须核查组合总限额、当前真实持仓、审批有效期以及事后实际成交对账。
- 研究案例通过验收绝不等于报单授权；资金使用全流程必须由具名责任人监督。

产品总验收：论证你的系统为何可靠

证据闭环
可追溯、可复算

门控约束
可阻断、可解释

跨会话连续
接续已核验进度

受控改进
可评估、可回滚

- 请从具体利益相关方的风险需求出发，论证系统中某一项控制机制的必要性。
- 如实区分“已核验的控制器机制”、“已测量的模型行为”与“尚待建设的实盘扩展”。

举手回答