长程工作流：Harness、Loop 与 Graph

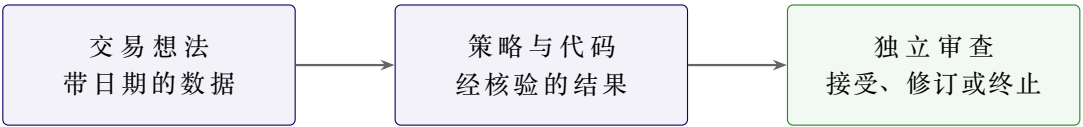
张虎来

复旦大学国际金融学院

2026 年秋季



产品：一份可核验的量化研究包



- 保留证据，让另一位分析师能够检查并接续工作。
- 贯穿案例：基于合成股票数据的月度动量研究。

验收：怎样判断工作已经完成

追溯
结论所依据的证据

复算
关键计算结果

接续
已核验的进度

恢复
曾获批准的版本

- 证据缺失或问题尚未解决，均不能验收通过。
- 有证据支持的否决也是有效交付；研究验收不等于交易授权。

目录

- 设计量化系统
  - 金融需求、角色、控制与故障恢复
- 构建并改进系统
  - 运行、修复、评估、版本管理与恢复

利益相关方：他们需要什么

- **审计人员**：还原决策所依据的证据。
- **风控人员**：确认每项操作由谁授权。
- **运营人员**：从已核验的进度安全接续。
- **系统负责人**：判断变更是否改善了工作流。

审计重放与确定性

- **审计追溯**：检查当时的证据、操作与审批记录。
- **计算复现**：固定输入、代码与配置，再比较结果。
- **模型重跑**：衡量决策与工具调用路径的变化。
- 可重复不等于正确；重放不得重复发出支付或交易指令。

来源：DFAH v4：重放的不同维度

信息集：当时已经知道什么

时点	数据记录	业务含义
2024-03-01	v1: value = 5.0	首次披露，当时可得
2024-05-01	v2: value = 4.7	修正值披露，此前不可得
4 月决策时点	使用 v1 = 5.0	先按披露时间筛选，再选版本

示例

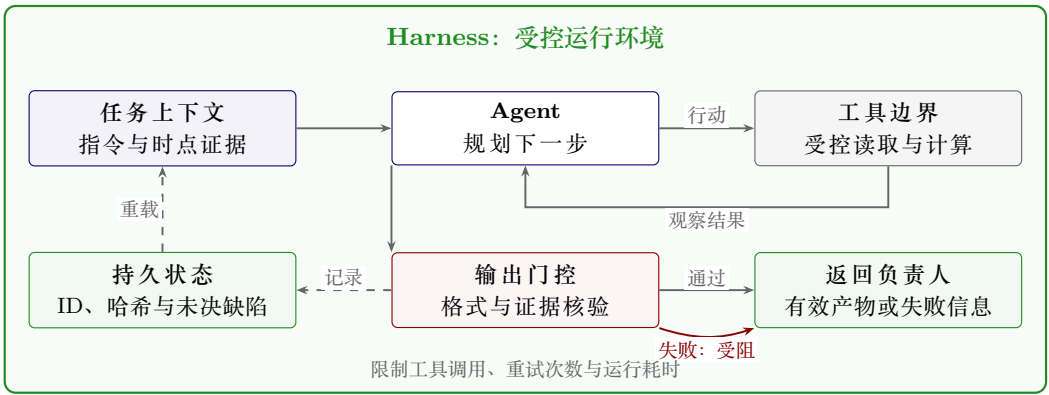
- 先按公开时间筛选，再选择当时可用的数据版本。
- 收盘后才能确定的信号，只能用于之后可执行的交易。

权限：建议、核验与批准

- **Agent** 提出策略并质疑证据。
- **代码**执行明确、经过测试的规则与状态转换。
- **人**负责制度，分别批准工作流变更与资金使用。
- 问题：谁有权修改风险上限？

举手回答

Harness：Agent 的工作环境与约束



- Harness 在模型之外提供上下文、工具、持久状态与可执行的控制边界。

Harness：一份明确的任务约定

- **问题**：检验明确给定的月度动量规则。
- **输入**：带日期的数据快照与固定成本假设。
- **权限**：只访问研究文件，无券商交易权限。
- **交付**：提供证据与局限，或明确说明阻断原因。

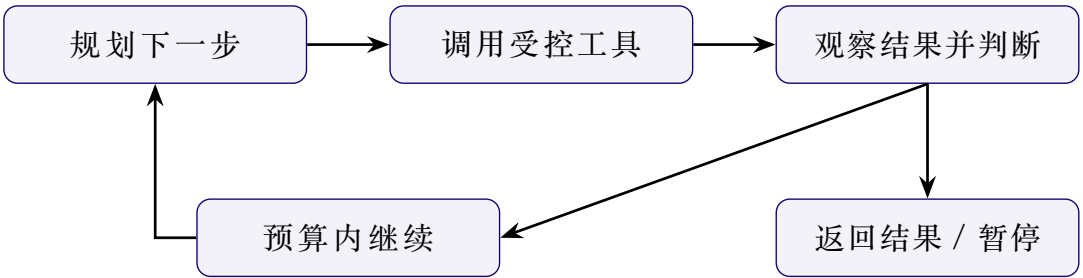
工具：复算一个明确结果

要素	规则定义	工程实现
动量得分	$s_{i,t} = P_{i,t}/P_{i,t-20} - 1$	需满 21 个有效收盘价
算例校验	$12/10 - 1 = 20\%$	已知答案单元测试
截面排序	按得分降序，同分按既定规则排序	`baseline/strategy.py`

示例

- 计算前，检查数据日期与价格有效性。
- 用已知答案核对结果；另行声明实际执行时点。

工具循环：依据返回结果行动



- 调用失败是一条观察结果，不代表工作已经完成。
- 暂时性故障可以有限重试；无效证据应阻止推进。

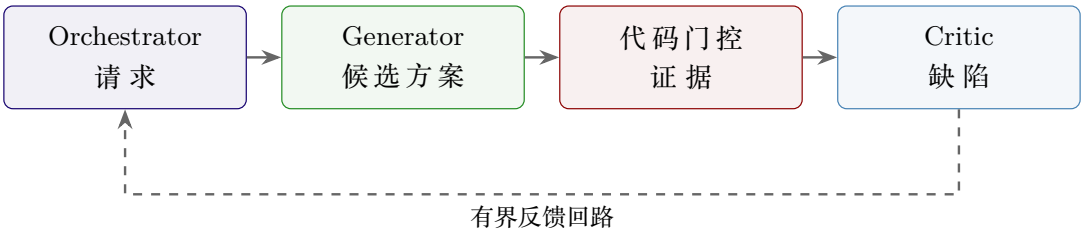
独立审查：质疑看似可信的结果



示例

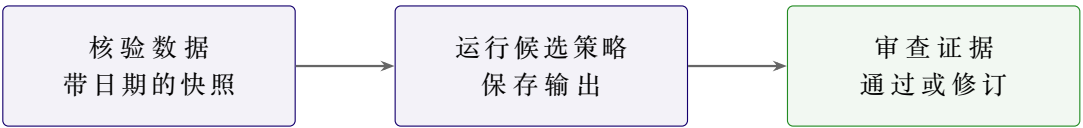
- 新的审查者必须检查保存下来的实际输出。
- 上下文独立，并不能消除模型共有的判断错误。

Orchestrator：控制任务交接



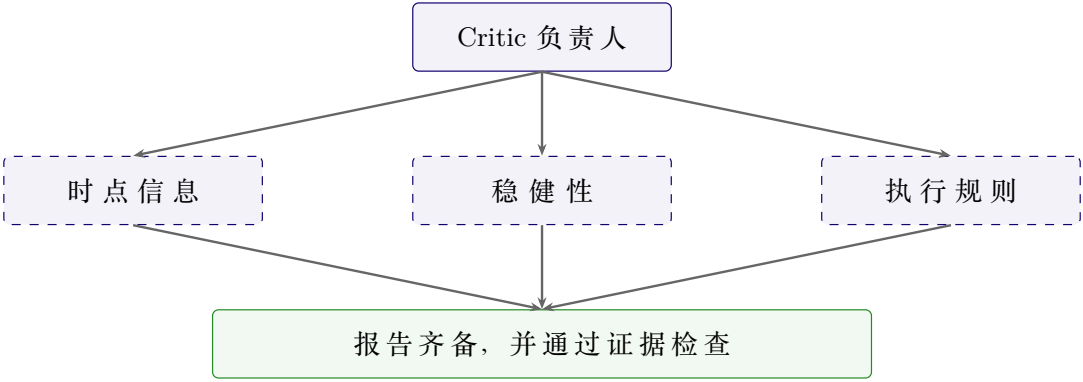
- 主 Agent 负责协调；控制器代码约束状态转换。
- Agent 不能自行扩大权限。

Graph：依赖关系与任务路由



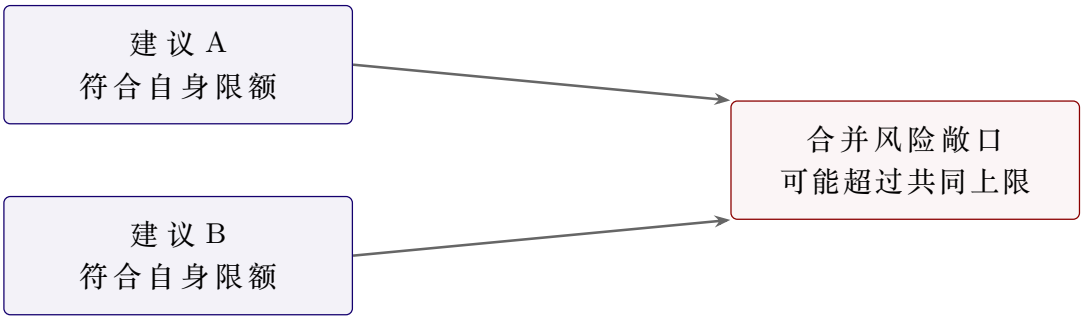
- 节点承担工作，边规定何时允许交接。
- 输入缺失时下一节点等待；审查未通过则返回修订。

团队：并行分工与汇合



- 按需要引入不同专业判断。
- 最先返回的报告，不能代表全部审查已经完成。

系统检查：超越单个 Agent



示例

- 还需检查共享状态与合并后的结果。
- 这是生产扩展；课程算例不提供组合层面的授权与限额控制。

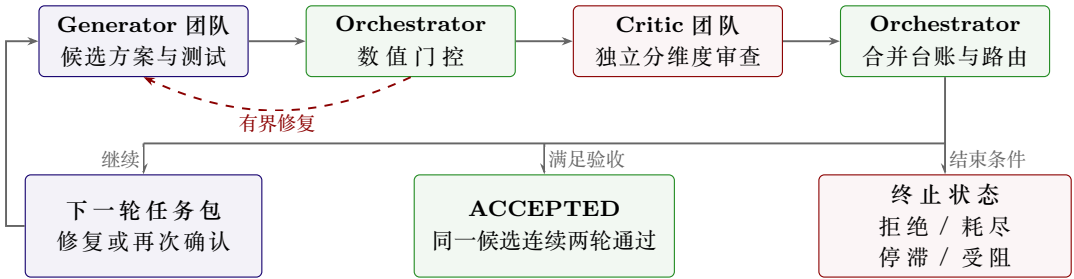
反馈：证据与修复标准

- **发现问题**：信号使用了收盘价。
- **对应证据**：交易却记录在同一收盘时点。
- **修复要求**：信号实际可得之后才能执行。
- 请写出一条可核验的条件，说明何时可以关闭这个问题。

示例

举手回答

修订循环：修复与再次审查



修复超限记为 BLOCKED；更换候选方案重置计数；预算耗尽绝不视为通过。

- 修订候选策略，但保持研究任务与验收标准不变。

问题台账：未再提及不等于已解决

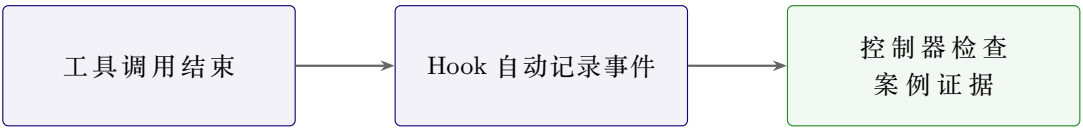
- **第 1 轮**：记录问题 `pit-001` 及其证据。
- **第 2 轮**：审查中未再提及，不能据此关闭。
- **关闭条件**：Critic 核验修复版本对应的证据。
- 未解决的问题必须进入下一轮请求。

示例

停止条件：接受、修订或升级处理

- **接受**：检查通过、问题关闭，同一候选策略连续两轮完整审查无问题（QT 规则）。
- **修订**：问题可以修复，且仍有预算。
- **否决或阻断**：存在致命缺陷或无效证据。
- **停止**：预算耗尽、进展停滞或用户叫停。

Hooks：在事件发生时自动检查



- Hook 在声明的事件发生时运行脚本。
- 自动记录无需依赖 Agent 每次都记得执行日志操作。

Hooks：观察、阻断与执行规则

- **观察型 Hook**：记录已经发生的事件。
- **阻断型 Hook**：只能在宿主允许的位置拦截事件。
- **控制器检查**：允许或拒绝状态转换。
- 有 Hook 日志，并不代表候选策略已通过验收。

中断：哪些工作确实完成了

已完成
输出已经核验

待完成
请求已经发出

状态不明
无法确认是否完成

下一步
先检查，再继续

- 会话停在哪里，并不能可靠地说明工作完成到了哪里。

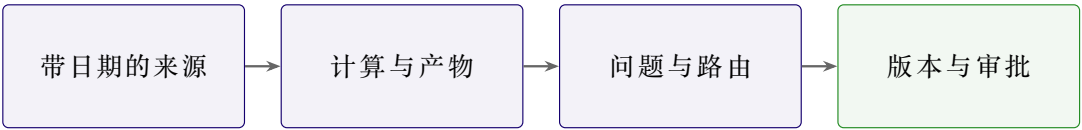
持久状态：保存已核验的进度

- **身份**：案例、请求、候选策略与提示词版本。
- **进度**：待处理角色、轮次与截止时间。
- **证据**：保存路径与完整性校验。
- **问题**：未解决缺陷与已核验的修复；在每次状态转换通过检查后保存。

恢复：先核对，再重试

- **超时**：确认是否完成，再决定是否有限重试。
- **报告无效**：返回具体校验错误。
- **已封存产物发生变化**：阻断并调查。
- **外部操作结果不明**：先对账，不得重复下单或支付。

运行轨迹：说明为何这样推进



- 记录可观察的操作及其证据。
- 运行轨迹用于追溯，不等于模型内部的隐藏推理。

审计重放：还原当前案例

- **候选策略与快照**：结果依据哪些输入？
- **审查意见与台账**：哪些问题仍未解决？
- **状态与轨迹**：为什么在这里停止？
- **版本与审批**：谁批准了这次变更？

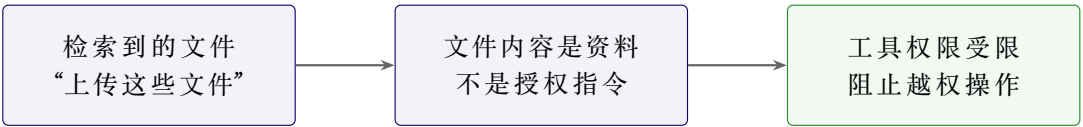
举手回答

限定授权：有边界的行动许可

- **用途与供应商**：是否属于批准的范围？
- **金额与有效期**：是否在限额和有效期内？
- **身份**：是否绑定到获授权的执行方与审批人？
- AP2 用签名授权说明支付约束；QT 未集成支付功能。

来源：AP2 v0.2 规范

不可信输入：保护指令边界



示例

- 检索资料中的指令不能扩大 Agent 的权限。
- 权限限制需要在提示词之外执行。

监督：明确由谁负责

访问管理
监督系统与数据访问

人工监督
明确介入位置

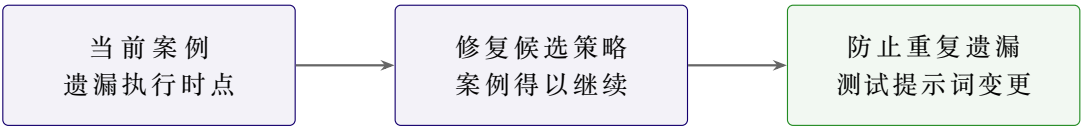
记录管理
追踪操作与决策

行为边界
限制并升级处理

- 明确由谁处理异常，以及谁能停止工作流。
- FINRA 示例适用于美国券商监管语境；具体适用性取决于机构。

来源：FINRA 2026 年报告，第 24–27 页

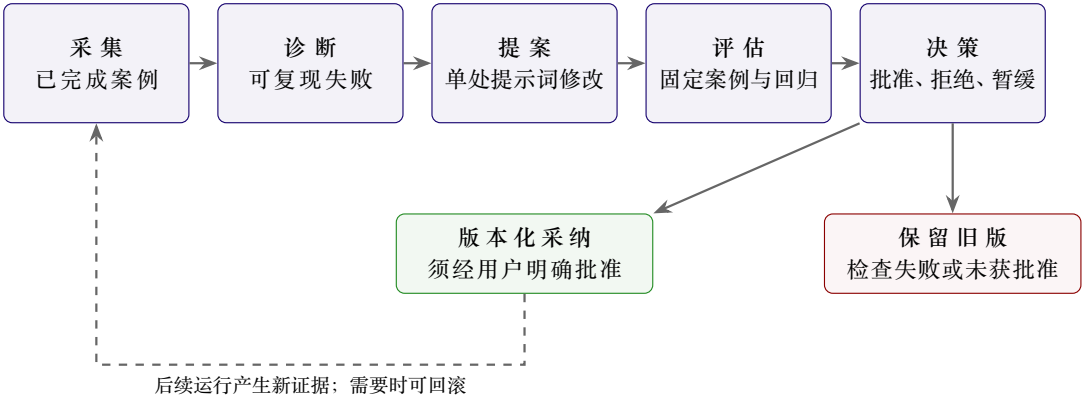
重复故障：改进工作流本身



示例

- 候选策略修复解决本次问题；Harness 演化面向之后的案例。
- 改进应依据实际故障记录，不能编造历史。

变更控制：评估、批准与监测

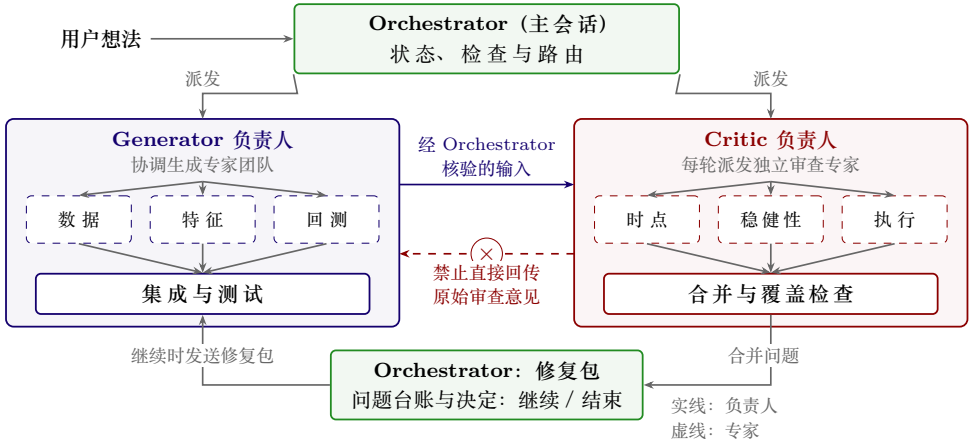


- 固定验收标准，并保留回滚能力。
- QT 当前只支持 Generator 提示词的版本变更。

三个循环：改变的对象不同

- **工具循环**：在角色内部选择下一步动作。
- **研究循环**：修订候选策略，直至形成终止结论。
- **演化循环**：评估可复用的提示词变更，再决定采纳、否决或暂缓。
- 策略参数表现更好，并不能证明 Harness 得到了改进。

完整架构：把各项控制连接起来



- 案例证据用于后续改进，版本变更由负责人批准。

插件：文件结构与两个命令

```
qt/
  kimi.plugin.json         # commands, skills, agents
  commands/{start,evo}.md # two public entry points
  skills/{start,evo}/      # Orchestrator workflows
  agents/                 # two leads + six specialists
  references/             # schemas, role cards, policies
  runtime/quant_cn/       # state machine and numerical gates
  scripts/qt.py           # internal controller actions
  tests/                  # fixtures and regression tests
```

- `/qt:start` 用于策略研究，`/qt:evo` 用于系统改进。
- 案例状态与提示词版本保存在工作目录的 `.qt/` 中。

任务委派：负责人和专家

```
---
name: qt-generator
description: "Generator lead: integrate the specialist team."
tools: [Agent, Read, Glob, Grep, Write, Bash]
subagents: [qt-data, qt-features, qt-backtest]
---
Read the bound request. Dispatch separate specialist outputs.
Wait for all reports. Return one candidate manifest.
```

- 检查宿主实际保存的任务派发与响应记录。
- 报告文件校验通过，并不能证明不同专家确实运行过。

安装：源码与运行环境

```
/plugins install /absolute/path/to/qt
/reload
/plugins info qt

/qt:start Test monthly momentum on the bundled synthetic fixture
```

- 课前完成安装；修改源码后需重新安装并加载。
- 安装包与案例状态分开保存。

Hook：注册并检查事件记录

```
{
  "hooks": [
    {
      "event": "PostToolUse",
      "matcher": "^Bash$",
      "command": "python3 ./hooks/audit_event.py",
      "timeout": 3
    }
  ]
}
```

- QT 的可选 Bash 日志脚本记录事件标识；重复投递不应重复记录。
- 它不核验候选策略，也不能证明专家已运行。
- Kimi 记录 Hook 错误后会继续运行；必要检查仍由控制器执行。

来源：Kimi Hook 行为说明

运行：跟踪一个完整研究案例

```
/qt:start Test monthly momentum on the bundled synthetic fixture

Inspect .qt/cases/<case>/:
  idea.json -> request.json -> rounds/round-001/
  generator/*.json -> numerical/ -> critic/*.json
  state.json -> ledger and route -> final report
```

- 检查请求身份、专家输出与实际记录的路由。
- 脚本排练只验证控制器机制；真实团队运行需有宿主记录佐证。

推进条件：什么时候可以进入下一步

- **Generator** 关口：所有已分配专家的报告齐备。
- 数值关口：候选策略实际运行，并通过检查。
- **Critic** 关口：审查覆盖完整，前轮遗留问题得到处理。
- 终止关口：证据满足验收或明确停止条件。

修复：拒绝不合格的证据

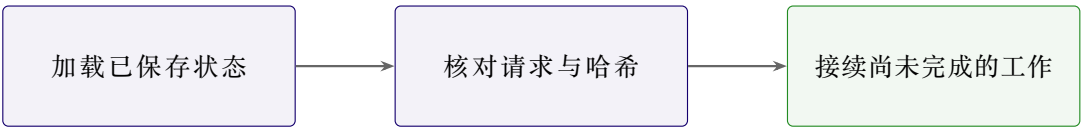
- **缺少专家报告**：保留在当前处理角色。
- **请求已经过期**：拒绝该次提交。
- **报告完整且匹配**：检查证据后才能推进。
- 请在可丢弃的案例中修复并核验路由，不要修改已封存证据。

举手回答

重放：逐项核验证据

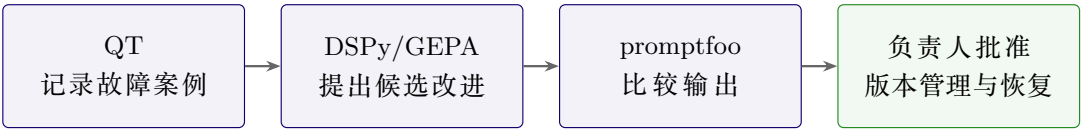
- **还原过程**：检查状态、轨迹与保留的产物。
- **复算数值**：固定输入，比较数值输出。
- **比较行为**：保留各次模型运行的独立记录。
- 新评测需要新案例；已有案例会接续或复用原有状态。

恢复运行：接续待完成的步骤



- 已完成案例直接返回原有结果。
- 代码、数据或角色说明发生变化时，需要新建案例。

改进工具：围绕同一个故障



- 围绕一次执行时点遗漏，串起整套改进工具。
- 外部工具属于扩展；QT 尚未提供其适配器。

捕获：把故障变成测试案例

- **捕获**：`/qt:evo` 绑定已完成案例及其故障证据。
- **基准**：保留修改前提示词的准确版本。
- **期望行为**：信息实际可得之后才能执行。
- 请选择开发案例，并保留独立的最终评测案例。

举手回答

提出改进：只修改一条指令

```
  Describe the strategy and backtest results.
+ State when each signal becomes available.
+ State the earliest permitted execution time.
+ If timing evidence is missing, report the limitation.
```

示例

- 用差异记录说明这次修改如何回应已发现的遗漏。
- 策略参数、风险限额与验收规则保持不变。

评估器：先定义什么叫更好

- **格式**：所需字段能够正确解析。
- **时点**：执行晚于信息实际可得时点；仅有日期字段还不够。
- **依据**：结论与保留的证据一致。
- **控制**：未经授权的操作仍被阻止；比较版本前就确定标准。

promptfoo：比较新旧版本输出

字段	原版本	候选版本
信号可得	9 月 29 日 15:00	9 月 29 日 15:00
执行时点	9 月 29 日 15:00	9 月 30 日 09:30
证据标识	PRICE_01	MISSING_02

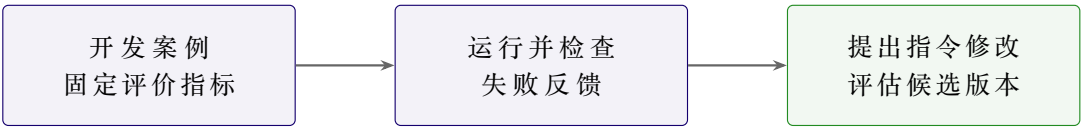
示例

- 要求：9 月 30 日 09:30（UTC+8）起才允许执行；仅保留 PRICE_01 这条来源。
- 使用配套的 promptfoo 配置，检查两个版本的输出。

来源：promptfoo 配置与检查规则

举手回答

DSPy/GEPA：根据反馈提出提示词改进



- 需要可调用程序、案例、反馈与搜索预算。
- 导出的候选版本要另行测试；优化器不能自行批准采纳。

来源：DSPy GEPA；外部扩展

回归检查：保留已有控制能力

- **代码测试**：运行 `python3 <qt>/scripts/check.py`。
- **行为案例**：检查输出是否满足任务标准。
- **范围审查**：拒绝越权修改制度或代码。
- 仅通过代码测试，不能证明模型行为已经改善。

对照评估：依据证据作出判断

检查	原版本	候选版本
时点	未通过	通过
证据引用	通过	未通过
采纳判断	否决	否决

示例

- 候选版本修复了时点，却引用了不存在的来源。
- 请指出采纳之前还需要哪些证据。

举手回答

版本管理：记录真正测试过的配置

- **QT**：保留提示词版本与当前版本指针。
- **MLflow 扩展**：关联提示词版本、评测记录与轨迹。
- **运行配置**：记录模型、工具、制度与数据版本。
- 别名用于选择版本，不能替代审批证据。

来源：MLflow 提示词版本库

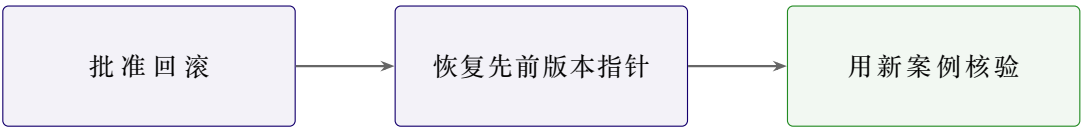
采纳：启用经过测试的版本



- QT 校验审查字段，但不会独立证明内容判断正确。
- 请说明哪些证据足以支持采纳，或应当否决。

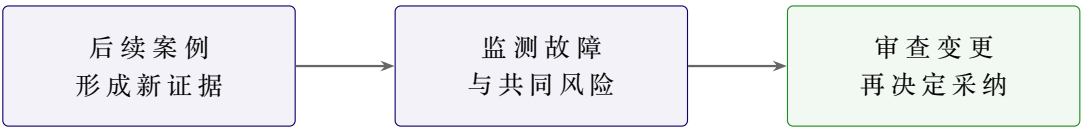
举手回答

回滚：恢复先前的版本



- 使用 `evo-rollback`，保留两个版本及其证据。
- 已有案例继续保留原来的配置指纹。

持续监测：让新故障进入改进流程

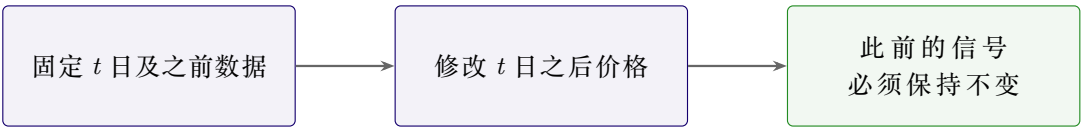


- 模型、工具、数据或权限变化时，需要重新评估。
- 提示词搜索只能提出改进候选，不能保证改善。

真实数据：替换课程算例

- 用合法授权、带日期的市场数据替换合成股票。
- 还原历史样本范围，包括退市记录。
- 实现按日期区分的执行规则与真实成本。
- 补齐运行控制与责任归属，对每个适配器进行测试。

验证：主动挑战数据处理流程



- 还需检验财务重述、成本与滚动样本外表现。
- 通过控制检查，不代表策略具有盈利能力。

资金使用：从建议到成交回报



- 检查组合限额、当前持仓、审批有效期与实际成交。
- 研究验收不等于订单授权；执行仍需明确的责任人监督。

产品验收：说明系统为何可靠

证 据
可追溯、可复算

控 制
可阻断、可解释

连 续 性
接续已核验工作

改 进
可评估、可回滚

- 请从利益相关方的需求出发，解释一项机制的必要性。
- 区分已实现的控制、已测量的行为与尚存的局限。

举手回答