长程工作流：Harness、Loop 与 Graph

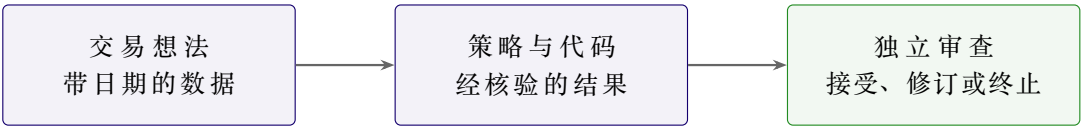
张虎来

复旦大学国际金融学院

2026 年秋季



产品：一份可核验的量化研究包



- 保留证据，让另一位分析师能够检查并接续工作。
- 贯穿案例：基于合成股票数据的月度动量研究。

验收：怎样判断工作已经完成

追溯
结论所依据的证据

复算
关键计算结果

接续
已核验的进度

恢复
曾获批准的版本

- 证据缺失或问题尚未解决，均不能验收通过。
- 有证据支持的否决也是有效交付；研究验收不等于交易授权。

目录

- 设计量化系统
  - 金融需求、角色、控制与故障恢复
- 构建并改进系统
  - 运行、修复、评估、版本管理与恢复

利益相关方：他们需要什么

利益相关方	具体要求
审计人员	这个决策依据什么?
风控人员	谁授权了这个操作?
运营人员	从哪一步恢复才可靠?
系统负责人	改了什么，是否确有改善?

- Topic 2 让任务可以复用；本讲让跨步骤、跨会话的工作始终受控。

审计重放与确定性

问题	比较什么
审计追溯	当时的证据、操作与审批
计算复现	冻结输入、代码与计算结果
模型重跑	新生成的决策与工具调用路径

- 结果可重复，不代表结果正确。
- 重放证据时，不得再次发出真实支付或交易指令。

来源：DFAH v4：重放的不同维度

信息集：当时已经知道什么

时点	数据记录	业务含义
2024-03-01	v1: value = 5.0	首次披露，当时可得
2024-05-01	v2: value = 4.7	修正值披露，此前不可得
4 月决策时点	使用 v1 = 5.0	先按披露时间筛选，再选版本

示例

- 先按公开时间筛选，再选择当时可用的数据版本。
- 收盘后才能确定的信号，只能用于之后可执行的交易。

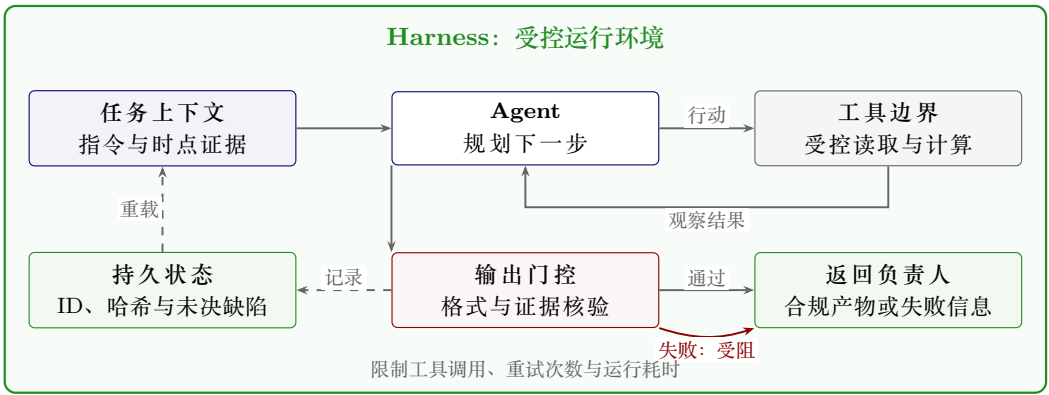
权限：建议、核验与批准

责任主体	职责
Agent	提出策略，质疑证据
代码	执行明确的检查与状态转换规则
人	负责制度，批准版本与资金使用

- 问题：谁有权修改风险上限?
- 研究结论、提示词版本采纳与交易授权，是三个不同的决策。

举手回答

Harness：Agent 的工作环境与约束



- Harness 在模型之外提供上下文、工具、持久状态与可执行的控制边界。

Harness：一份明确的任务约定

任务约定	月度动量案例
问题	检验明确给定的动量规则
输入	带日期的快照与固定成本假设
权限	研究文件；无券商交易权限
交付	证据、局限，或说明阻断原因

- 先确定任务与权限，再让 Agent 开始工作。

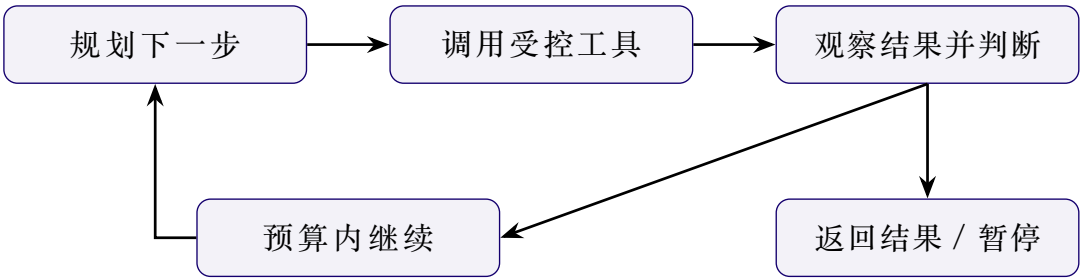
工具：复算一个明确结果

要素	规则定义	工程实现
动量得分	$s_{i,t} = P_{i,t}/P_{i,t-20} - 1$	需满 21 个有效收盘价
算例校验	$12/10 - 1 = 20\%$	已知答案单元测试
截面排序	按得分降序，同分按既定规则排序	`baseline/strategy.py`

示例

- 计算前，检查数据日期与价格有效性。
- 用已知答案核对结果；另行声明实际执行时点。

工具循环：依据返回结果行动



- 调用失败是一条观察结果，不代表工作已经完成。
- 暂时性故障可以有限重试；无效证据应阻止推进。

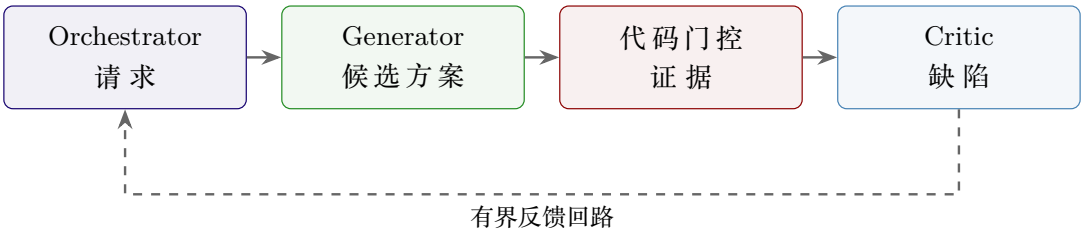
独立审查：质疑看似可信的结果



示例

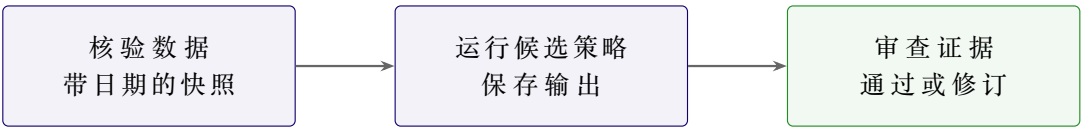
- 新的审查者必须检查保存下来的实际输出。
- 上下文独立，并不能消除模型共有的判断错误。

Orchestrator：控制任务交接



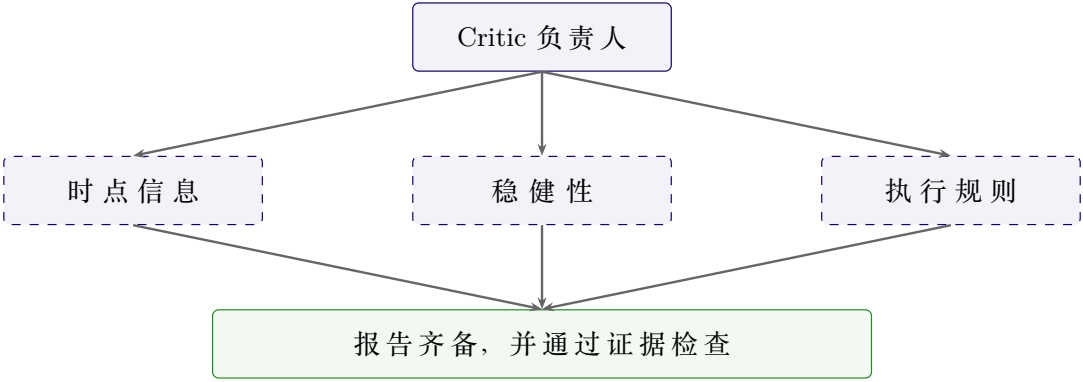
- 主 Agent 负责协调；控制器代码约束状态转换。
- Agent 不能自行扩大权限。

Graph：依赖关系与任务路由



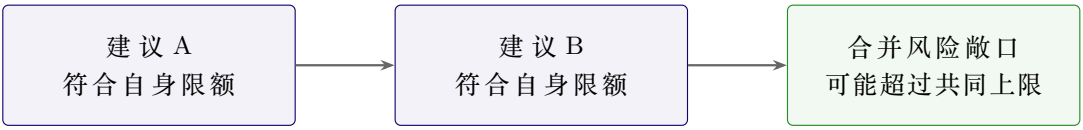
- 节点承担工作，边规定何时允许交接。
- 输入缺失时下一节点等待；审查未通过则返回修订。

团队：并行分工与汇合



- 按需要引入不同专业判断。
- 最先返回的报告，不能代表全部审查已经完成。

系统检查：超越单个 Agent



示例

- 还需检查共享状态与合并后的结果。
- 这是生产扩展；课程算例不提供组合层面的授权与限额控制。

反馈：证据与修复标准

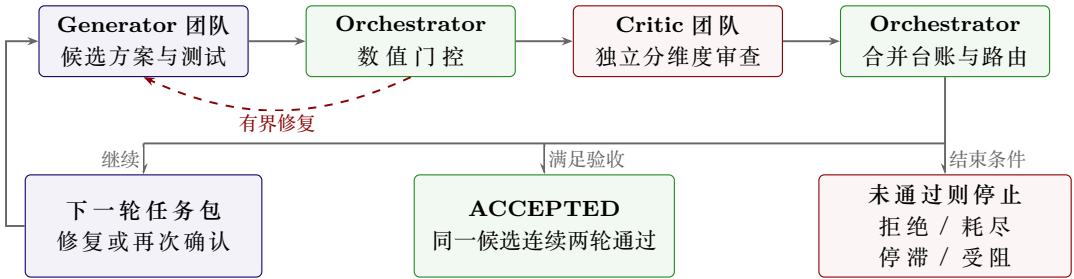
问题记录	所需证据
时点缺陷	信号使用收盘价
受影响产物	交易却记录在同一收盘时点
修复标准	信号可得之后才能执行交易

示例

- 请为这个问题写出一条可核验的关闭条件。

举手回答

修订循环：修复与再次审查



修复超限记为 BLOCKED；更换候选方案重置计数；预算耗尽绝不视为通过。

- 修订候选策略，但保持研究任务与验收标准不变。

问题台账：未再提及不等于已解决

阶段	审查证据	台账状态
第 1 轮	`pit-001`：误用未来数据	缺陷待解决
第 2 轮	Critic 未提及 `pit-001`	仍保持开启
核验修复	Critic 引用修复后的产物证据	记录理由后关闭

示例

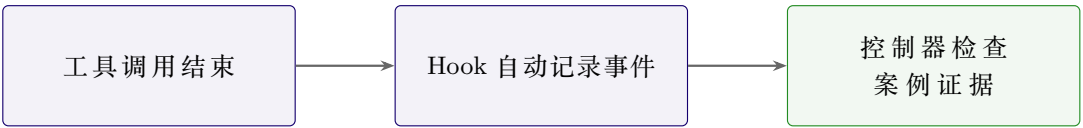
- 关闭问题，需要对应修复版本的证据。
- 未解决的问题必须进入下一轮请求。

停止条件：接受、修订或升级处理

证据或条件	下一步
检查通过，问题已关闭	执行验收规则
可以修复，仍有预算	继续修订
致命缺陷或无效证据	否决或阻断
无进展、预算耗尽或用户叫停	停止并保存原因

- QT 要求同一候选策略连续两轮完整审查无问题；这是课程实现的规则。

Hooks：在事件发生时自动检查



- Hook 在声明的事件发生时运行脚本。
- 自动记录无需依赖 Agent 每次都记得执行日志操作。

Hooks：观察、阻断与执行规则

机制	权限边界
观察型 Hook	记录已经发生的事件
宿主支持的阻断型 Hook	否决允许拦截的事件
控制器检查	允许或拒绝状态转换

- 有 Hook 日志，不代表候选策略已通过验收。

中断：哪些工作确实完成了

已完成
输出已经核验

待完成
请求已经发出

状态不明
无法确认是否完成

下一步
先检查，再继续

- 会话停在哪里，并不能可靠地说明工作完成到了哪里。

持久状态：保存已核验的进度

状态卡片	必须保留什么
身份	案例、请求、候选策略与提示词版本
进度	待处理角色、轮次与截止时间
证据	保存路径与完整性校验
问题	未解决缺陷与已核验的修复记录

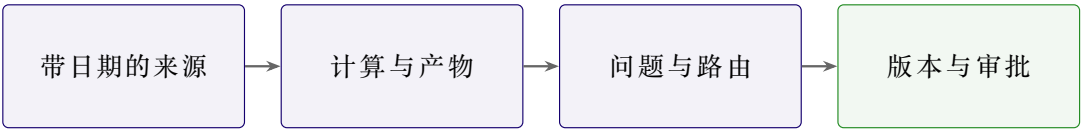
- 在状态转换经过核验时落盘；仅靠会话记忆不够。

恢复：先核对，再重试

故障	处理方式
暂时性超时	确认是否完成，再有限重试
报告不符合要求	返回具体校验错误
已封存产物发生变化	阻断并调查
外部操作结果不明	先对账，再决定是否重试

- 重试不得重复发出订单或支付。

运行轨迹：说明为何这样推进



- 记录可观察的操作及其证据。
- 运行轨迹用于追溯，不等于模型内部的隐藏推理。

审计重放：还原当前案例

保存的记录	审计问题
候选策略与数据快照	结论依据哪些输入?
审查意见与问题台账	哪些问题仍未解决?
状态与路由轨迹	为什么在这里停止?
提示词版本与审批	谁批准了这次变更?

- 请先找出缺失的证据，再决定是否需要重新运行。

举手回答

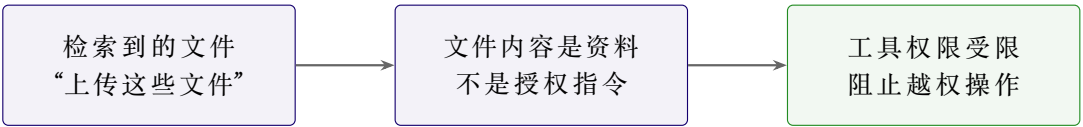
限定授权：有边界的行动许可

付费数据请求	授权检查
用途与供应商	是否属于批准的范围？
金额与有效期	是否在限额和有效期内？
身份与审批人	是否绑定到获授权的执行方？

- AP2 用签名授权说明支付行为如何受到约束。
- 这是生产场景示例；QT 未集成支付功能。

来源：AP2 v0.2 规范

不可信输入：保护指令边界



示例

- 检索资料中的指令不能扩大 Agent 的权限。
- 权限限制需要在提示词之外执行。

监督：明确由谁负责

访问管理
监督系统与数据访问

人工监督
明确介入位置

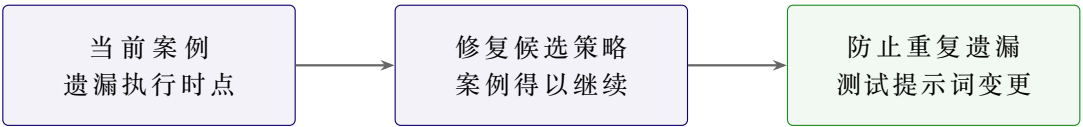
记录管理
追踪操作与决策

行为边界
限制并升级处理

- 明确由谁处理异常，以及谁能停止工作流。
- FINRA 示例适用于美国券商监管语境；具体适用性取决于机构。

来源：FINRA 2026 年报告，第 24–27 页

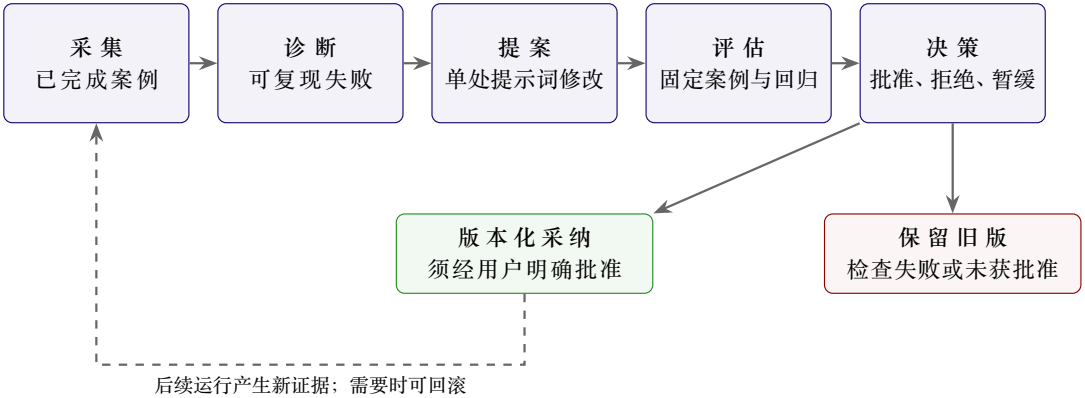
重复故障：改进工作流本身



示例

- 候选策略修复解决本次问题；Harness 演化面向之后的案例。
- 改进应依据实际故障记录，不能编造历史。

变更控制：评估、批准与监测



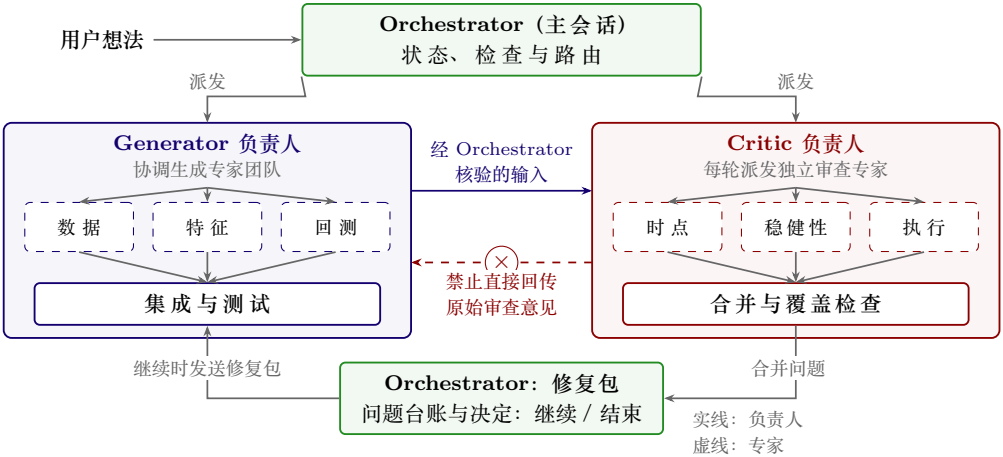
- 固定验收标准，并保留回滚能力。
- QT 当前只支持 Generator 提示词的版本变更。

三个循环：改变的对象不同

循环层次	改动对象	停止条件
工具循环	角色内部的下一步动作	产出合规结果、报错或达上限
研究循环	当前案例的候选策略	得出明确的案例终局结论
演化循环	可复用的 Harness 提示词	批准采纳、拒绝或暂缓

- 回测参数表现更好，并不能证明 Harness 得到了改进。

完整架构：把各项控制连接起来



- 案例证据用于后续改进，版本变更由负责人批准。
- 生产授权与组合整体风险控制仍需另行实现。

插件：文件结构与两个命令

```
qt/
  kimi.plugin.json         # commands, skills, agents
  commands/{start,evo}.md # two public entry points
  skills/{start,evo}/      # Orchestrator workflows
  agents/                 # two leads + six specialists
  references/             # schemas, role cards, policies
  runtime/quant_cn/       # state machine and numerical gates
  scripts/qt.py           # internal controller actions
  tests/                  # fixtures and regression tests
```

- `/qt:start` 用于策略研究，`/qt:evo` 用于系统改进。
- 案例状态与提示词版本保存在工作目录的 `.qt/` 中。

任务委派：负责人和专家

```
---
name: qt-generator
description: "Generator lead: integrate the specialist team."
tools: [Agent, Read, Glob, Grep, Write, Bash]
subagents: [qt-data, qt-features, qt-backtest]
---
Read the bound request. Dispatch separate specialist outputs.
Wait for all reports. Return one candidate manifest.
```

- 检查宿主实际保存的任务派发与响应记录。
- 报告文件校验通过，并不能证明不同专家确实运行过。

安装：源码与运行环境

```
/plugins install /absolute/path/to/qt
/reload
/plugins info qt

/qt:start Test monthly momentum on the bundled synthetic fixture
```

- 课前完成安装；修改源码后需重新安装并加载。
- 安装包与案例状态分开保存。

Hook：注册并检查事件记录

```
{
  "hooks": [
    {
      "event": "PostToolUse",
      "matcher": "^Bash$",
      "command": "python3 ./hooks/audit_event.py",
      "timeout": 3
    }
  ]
}
```

- QT 的可选 Bash 日志脚本记录事件标识；重复投递不应重复记录。
- 它不核验候选策略，也不能证明专家已运行。
- Kimi 记录 Hook 错误后会继续运行；必要检查仍由控制器执行。

来源：Kimi Hook 行为说明

运行：跟踪一个完整研究案例

```
/qt:start Test monthly momentum on the bundled synthetic fixture

Inspect .qt/cases/<case>/:
  idea.json -> request.json -> rounds/round-001/
  generator/*.json -> numerical/ -> critic/*.json
  state.json -> ledger and route -> final report
```

- 检查请求身份、专家输出与实际记录的路由。
- 脚本排练只验证控制器机制；真实团队运行需有宿主记录佐证。

推进条件：什么时候可以进入下一步

检查关口	必须具备的证据
Generator	所有已分配专家的报告
数值检查	候选策略已执行，检查已通过
Critic	完整审查与前轮遗留问题
终止判断	满足验收或明确停止条件

- 一句“已成功”不能替代所需产物。

修复：拒绝不合格的证据

提交内容	控制器应如何处理
缺少一位专家的报告	保留在当前处理角色
请求标识已经过期	拒绝该次提交
报告完整且匹配当前请求	检查证据后才能继续

- 请补齐缺失报告，并核验下一步路由。
- 使用可丢弃的练习案例，不要修改已封存的证据。

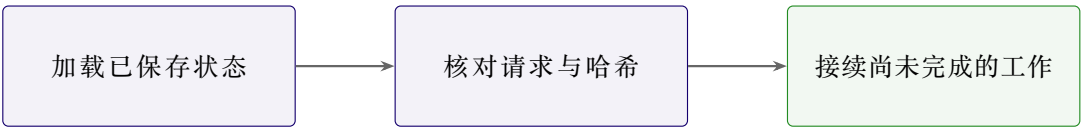
举手回答

重放：逐项核验证据

核验目标	QT 中的证据
还原过程	状态、轨迹与保留的产物
复算数值	冻结输入与数值输出
比较行为	独立案例及其模型运行记录

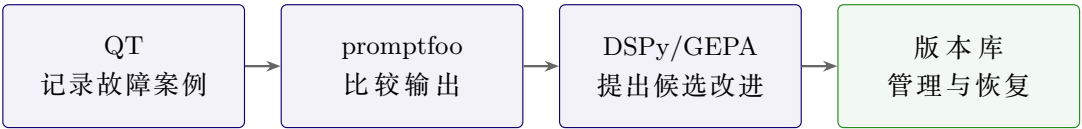
- 新评测需要新建案例。
- 重新启动已有案例，会接续或复用其已记录的状态。

恢复运行：接续待完成的步骤



- 已完成案例直接返回原有结果。
- 代码、数据或角色说明发生变化时，需要新建案例。

改进工具：围绕同一个故障



- 围绕一次执行时点遗漏，串起整套改进工具。
- 外部工具属于扩展；QT 尚未提供其适配器。

捕获：把故障变成测试案例

记录内容	形成的证据
已完成案例	原始请求与故障产物
原提示词	修改前的准确版本
期望行为	观测时点先于执行时点
案例划分	开发案例与保留的最终评测案例

- 使用 `/qt:evo`；内部由 `evo-prepare` 绑定来源案例。
- 请指出新测试必须保留哪些故障证据。

举手回答

提出改进：只修改一条指令

```
- Describe the strategy and backtest results.
+ State when each signal becomes available.
+ State the earliest permitted execution time.
+ If timing evidence is missing, report the limitation.
```

示例

- 用差异记录说明这次修改如何回应已发现的遗漏。
- 策略参数、风险限额与验收规则保持不变。

评估器：先定义什么叫更好

检查维度	通过标准
格式	所需字段能够正确解析
时点	执行发生在信息实际可得之后
依据	结论与保留的证据一致
控制	未经授权的操作仍被阻止

- 有日期字段，不代表日期就是正确的。
- 在看到候选版本结果之前确定检查标准。

promptfoo：比较新旧版本输出

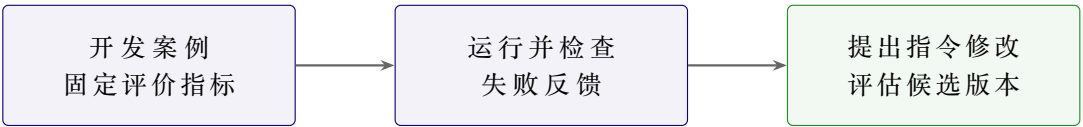
准备好的对照评测	核验内容
原提示词与候选提示词	案例与模型设置相同
Python 检查函数	时间顺序与证据引用
输出对照表	逐项失败原因与原始输出

- 先检查一个仍未通过的案例，再判断改进是否成立。
- 这是外部评估工具；QT 尚未内置适配器。

来源：promptfoo 配置与检查规则

举手回答

DSPy/GEPA：根据反馈提出提示词改进



- 需要可调用程序、案例、反馈与搜索预算。
- 导出的候选版本要另行测试；优化器不能自行批准采纳。

来源：DSPy GEPA；外部扩展

回归检查：保留已有控制能力

测试层次	可以证明什么
QT 代码测试	缺失报告与过期标识会被阻止
行为案例	输出满足既定任务标准
修改范围审查	没有越权修改制度或代码

- 运行 `python3 <qt>/scripts/check.py`。
- 仅通过代码测试，不能证明模型行为已经改善。

对照评估：依据证据作出判断

两个版本都需记录	决策用途
固定案例的输出与失败记录	检查通过或失败的原因
重复运行与资源用量	判断波动与运行成本
未参与调优的最终案例	检验选定版本的泛化表现
关键控制失败	无论总分多高都不能采纳

- 请用保存的原始输出，核对一项声称的改善。

举手回答

版本管理：记录真正测试过的配置

版本管理方式	保留内容
QT 本地版本库	提示词版本与当前指针
MLflow 对应工具	提示词版本、评测记录与轨迹
运行配置	模型、工具、制度与数据版本

- 别名用于选择版本，不能替代审批证据。
- MLflow 集成属于后续扩展。

来源：MLflow 提示词版本库

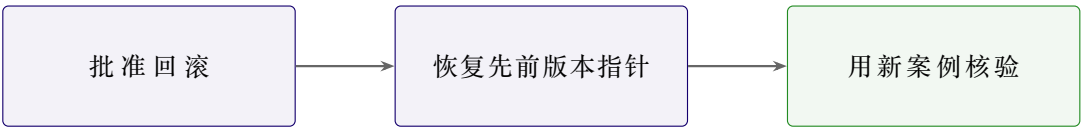
采纳：启用经过测试的版本



- QT 校验审查字段，但不会独立证明内容判断正确。
- 请说明哪些证据足以支持采纳，或应当否决。

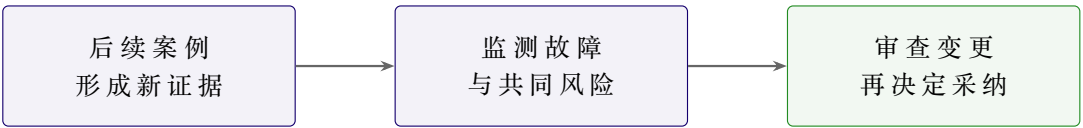
举手回答

回滚：恢复先前的版本



- 使用 `evo-rollback`，保留两个版本及其证据。
- 已有案例继续保留原来的配置指纹。

持续监测：让新故障进入改进流程



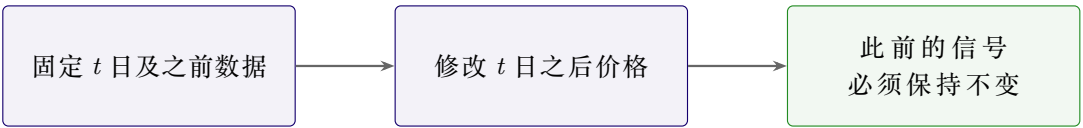
- 模型、工具、数据或权限变化时，需要重新评估。
- 提示词搜索只能提出改进候选，不能保证改善。

真实数据：替换课程算例

课程算例	生产要求
合成股票数据	合法授权、带日期的行情
固定样本	历史成分与退市记录
简化执行机制	按日期、板块区分规则与成本
本地状态	运行控制与责任归属

- 每个适配器都需要相应证据与测试。

验证：主动挑战数据处理流程



- 还需检验财务重述、成本与滚动样本外表现。
- 通过控制检查，不代表策略具有盈利能力。

资金使用：从建议到成交回报



- 检查组合限额、当前持仓、审批有效期与实际成交。
- 研究验收不等于订单授权；执行仍需明确的责任人监督。

产品验收：说明系统为何可靠

证 据
可追溯、可复算

控 制
可阻断、可解释

连 续 性
接续已核验工作

改 进
可评估、可回滚

- 请从利益相关方的需求出发，解释一项机制的必要性。
- 区分已实现的控制、已测量的行为与尚存的局限。

举手回答